Modeling Temporal Pointing with Visual Perception

팀 지금이니

박성용 김환욱 김진주 이용주

Professor : 이병주

Assistant : 한의엽

[Contents]

1 Background

2 Related Research

3 Theoretical Background

3.1 Reaction Time Distribution

3.2 Human Error Model

3.3 Internal Clock and Interval Timing

4 Proposed Research

5 Research Methodology

6 Research Result

7 Conclusion and Contributions

8 Limitation

9 Team Member

10 Reference

1. 연구 배경 및 필요성

Computational Rationality는 인간이 인지·행동 제약(bounded rationality) 속에서 기대 효용을 최대화하는 방향으로 행동한다고 가정하고, 이를 계산적 모델(RL)로 재현하여 인간 행동을 설명·예측하는 framework이다. HCI에서는 이 CR 이론에 따라 인간을 모사하는 RL agent를 구현하고, 이를 통해 인간의 행동동기를 분석하려는 시도들이 있었다. 하지만, 이러한 시도들은 대부분 spatial pointing task에 집중되었고, 시간적인 정보를 다루는 temporal pointing은 거의 다뤄지지 않았다. 인간은 인지 및 반응의 지연, 인식 오차, 학습과정에서의 초기 실수, 시간 간격 학습 및 시간 감각(internal clock)의 불확실성 등 다양한 인지적 요인들에 의해 제약을 받는다. 이러한 인간의 특성은 인지과학, 심리학, 인간-컴퓨터 상호작용(HCI), 교육공학 등 여러 분야에서 중요하게 다루어지며, 인간 행동을 보다 정밀하게 예측하거나 사용자 경험 혹은 인터페이스 설계하는 과정, 그리고 학습 보조 도구를 제작하는 데 있어 필요한 요소로 작용한다.

따라서, 본 연구는 두 개의 세부 목표를 통해 인간의 인지 제약, 계산 능력을 반영하여 인간의 행동 양상을 모사하는 RL 모델을 설계하고자 한다.

- 첫째, 일정한 간격으로 나타나는 시각 지표(visual cue)에 대해 초기에는 반응 속도만으로 버튼을 클릭하지만, 반복을 통해 간격을 인지하고 시간 간격에 맞추어 버튼을 누르는 행동 변화와 함께 인지 및 반응 지연의 분포를 포함한 인간의 불완전성을 지닌 모델 설계
- 둘째, Flappy Bird 같은 visual cue를 인식하는 게임에서 파이프가 다가올 때의 시점(state 또는 거리)에 반응하여 점프하는 인간 반응을 모사하는 모델 설계

2. 기존 연구의 한계

기존 연구들은 강화학습 모델 설계에서 지연, 불확실성, 실수 등의 인간적 요소를 명시적으로 포함하지 않는 경우가 많다. Lee & Oulasvirta(2016)의 연구에서는 시간적 포인팅 과제(temporal pointing)에서 인간의 오차율을 정량화하였으나, RL 기반 모델에 이러한 특성을 직접적으로 통합하지는 않았다. 또한 Deverett et al.(2019)에서는 심층 강화학습 에이전트의 간격 학습(interval timing)을 다루었으나, 인간의 반응 시간 분포를 정밀하게 재현하는 것이 목표는 아니었다. 또한, Moon et al.(2024)에서는 인간의 신체적 제약을 반영한 RL 에이전트를 구현하였지만, temporal pointing이 아닌 spatial task에 관한 것이었다.

인지적 비용(cognitive cost), 반응 속도 분포, 오류율을 RL 모델 내에 통합하려는 시도는 제한적이다. 일부 연구에서 지연된 관측이나 행동 실행 지연을 고려하기 시작했으나, 비주얼 큐 간격 학습과 같이 단순한 태스크에서 인간과 유사한 행동을 목표로 한 연구는 드물다. 따라서 본 연구는 인간 행동의 불완전성을 모사하는 RL 에이전트를 구현하고자 한다.

3. 이론적 배경

3.1 인지심리이론 (Human-based research)

3.1.1 Temporal Pointing

Temporal pointing은 시간 지각(temporal perception)과 운동 계획(motor planning)이 결합된 과정으로, 주어진 자극의 시간적 예측(temporal prediction)을 통해 반응 타이밍을 조절하는 행동을 의미한다.

2.1.2 반응 시간 분포 (Reaction Time Distribution)

반응 시간 분포는 동일 자극에 반복적으로 반응할 때 나타나는 반응 시간의 통계적 분포를 의미한다. 인간의 반응 시간은 평균 근처에 집중되지만, 조기 반응과 지연 반응으로 인해 긴 꼬리를 가지는 비대칭 분포(skewed distribution)를 보이는 것이 일반적이다.

2.1.3 인간 오류 모델 (Human Error Model)

인간 오류 모델은 작업 수행 과정에서 발생하는 다양한 실수의 패턴을 설명하는 이론적 틀이다[1]. 대표적으로 조기 반응(premature response), 지연 반응(delayed response), 무작위 오류(random lapse) 등이 있으며, 이는 일정 확률로 발생한다.

2.1.4 시간 인지 이론 (Internal Clock and Interval Timing)

인간은 사건 간 시간 간격을 추정할 수 있는 내부 메커니즘을 가지고 있다. 인간의 시간 추정은 완벽하지 않으며, 내재된 노이즈와 인지적 부하에 따라 편차를 보인다. 특히, 스칼라 성질(Scalar Property)은 인간의 시간 인지가 비례적 변동성(proportinal variability)를 보인다는 개념을 의미한다[2]. 즉, 짧은 시간 간격보다 긴 시간 간격을 예측할 때 오차의 절대값이 커지지만, 상대적 변동성(Coefficient of Variation)은 일정하게 유지된다는 것이다. 예를 들어, 1초를 맞추는 것 보다 2초를 맞출 때 평균 오차가 약 2배로 증가하는 경향을 보인다.

2.2 계산 모델 (Computational modeling)

2.2.1 Human Performance Modeling

Human Performance Modeling(HPM)은 인간이 주어진 과업을 수행할 때의 반응시간(reaction time), 정확도(accuracy), 오류율(error rate) 등을 예측하기 위한 정량적 접근으로, 인간의 인지·운동 과정을 계산적 절차로 표현한다. Fitts's

---

[1] Reason, J. (1990). *Human error*. Cambridge: Cambridge University Press.

[2] Wearden, John H. "Do humans possess an internal clock with scalar timing properties?." Learning and motivation 22.1-2 (1991): 59-83.

law[3]에서 손이나 포인터의 이동 거리(D)와 목표 폭(W)에 따라 이동 시간이 로그적으로 증가함을 보여주었고, 이후 연구들에서는 이를 확장하여 포인팅, 클릭, 터치 등 다양한 HCI 과업에서 사용자 수행을 예측하는 모델로 발전시켰다.

2.2.2 Computational rationality

Computational Rationality(CR)는 인간의 인지 과정이 환경적 제약과 계산 자원(cost) 안에서 최적화된 결과물이라는 관점에서 인간 행동을 설명하는 이론적 틀이다. 이 접근은 인간이 이상적인 최적 해를 추구하기보다는 제한된 정보 처리 능력과 시간·노력 등의 비용을 고려해 bounded optimality를 달성한다고 가정한다. 강화학습, 베이지안 추론 등 계산적 모델링 기법을 활용하여 의사결정, 주의 배분, 계획 등의 인지적 행동을 비용-편익 관점에서 예측하며, 휴리스틱이나 편향 또한 제한된 자원 하에서의 합리적 전략으로 해석한다.

4. 연구 목표

기존 computational rationality framework에서 다루는 task들은 시간적인 정보보다 공간적인 정보가 planning에 주가 되는 것이 대부분이었고, 원 논문에 언급된 blinking task과 같이 목표가 되는 정보가 화면 상에서 아예 사라지는 등 '시간적인 정보를 기억하는' 작업들을 다루지 않는다. 때문에 시간적 정보를 인지, 기억하고 예측하는 것을 설명하길 목표로 한다.

1. Blinking Task

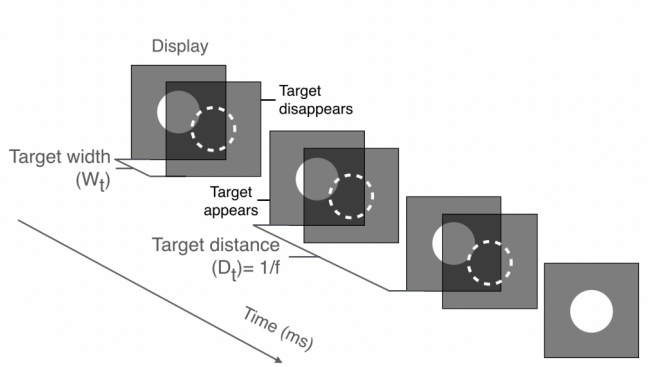

[그림1] Blinking task overview

주기적으로 제시되는 visual cue에 대해 초기에는 단순 반응 속도에 의존하여 버튼을 클릭하다가, 반복 학습을 통해 신호의 시간 간격을 internal clock을 이용하여 예측적으로 반응하는 행동 변화를 재현한다. 따라서 인지 및 반응 지연의 확률 분포, 실수 및 탐색적 행동을 포함시켜, 실제 인간 실험자의 데이터와 유사한 반응 양상을 보이는 RL 에이전트를 구현하고자 아래와 같은 세부 목표를 설정한다.

- 플래시 감지 및 시간 데이터 처리 **:**
  플래시가 나타나는 시점을 감지하고 감지 시간을 기록하여 시각 정보 기반의 반응 모델 구현
- 내부 시계 형성 및 학습 **:**
  플래시 간 시간 간격 데이터를 활용하여 모델이 스스로 간격을 예측할 수 있는 내부 시계 학습

---

[3] Fitts, P. M.. “The information capacity of the human motor system in controlling the amplitude of movement.”

- 클릭 행동 및 반응 지연 모델링 :
  모델이 시각 정보와 내부 시계를 바탕으로 클릭 타이밍을 결정하고, 실제 인간의 운동 지연과 오차를 반영한 클릭 결과를 데이터로 출력하도록 학습
- 성능 평가 및 개선 :
  모델의 정확도, 오탐율, 반응 시간 분석 등을 측정하여 인간 행동 유사도를 평가하여 알고리즘의 개선 방향 결정

2. Flappy Bird Task

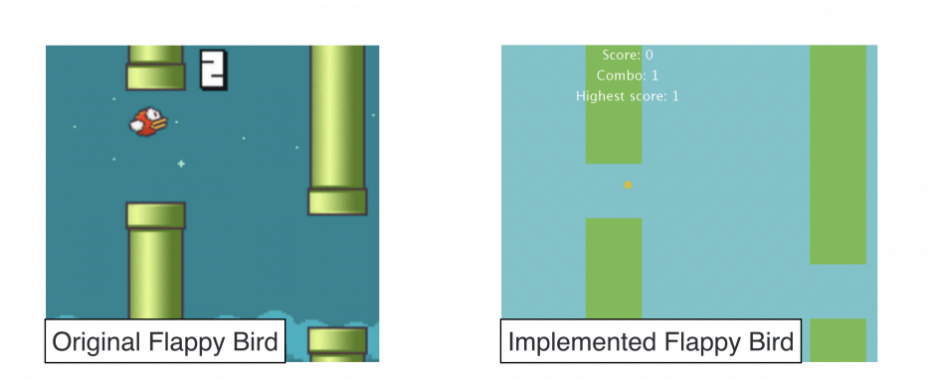

[그림 2] Flappy Bird 게임과 *Lee & Oulasvirta(2016)*에서 사용된 Flappy Bird 환경

더 복잡하고 동적인 temporal pointing task에 대해서도 인간 실험자 데이터를 잘 모사할 수 있는 RL 에이전트 구현하기 위해 아래와 같은 세부 목표를 설정한다.

- **Flappy Bird** 환경 내 지연 모델링 :
  관측과 행동 사이에 확률적 지연을 추가하여 사람의 시각/반응 지연 적용
- 실제 인간의 반응 시간 분포와 행동 패턴 재현 :
  파이프 간격이 급격히 변할 때의 실패율, 오버슈트/언더슈트 비율 등 행동 특성이 실제 인간과 비슷하도록 조정
- 정책 일반화 및 적응성 검증 :
  훈련되지 않은 파이프 간격이나 간격 조건에서 성능을 평가하여 Lee & Oulasvirta(2016)의 error rate 모델과 얼마나 일치하는지 검증

5. 연구 방법

1. 인간 데이터 수집 및 분석

Lee & Oulasvirta(2016)와 유사하게 Blinking task에 대한 데이터 수집 환경을 구성하고, 실험 설계를 하였다. 그 후, 실제 인간 데이터를 수집하여 task에 대한 반응 분포, 실패율을 분석하였다. 본 실험에서는 조원 4명이 각각 모든 난이도 조건에 대해 100회씩 수행하여 총 3600회의 데이터를 직접 수집하였다. 또한, 본 연구에서는 task의 난이도를 정량화하기 위해 Index of Difficulty (ID_t) 개념을 적용하였다.D_t(temporal distance)와 W_t(target width)는 task의 난이도를 결정하는

주요 요인으로, 목표가 멀수록(D_t가 클수록) 또는 목표 구간이 좁을수록(W_t가 작을수록) 수행이 어려워진다.

Task의 난이도 ID_t는 다음 식으로 정의된다:

$$ID_t = \log_2(D_t/W_t)$$

2. Blinking Task

Python과 Gym 라이브러리를 이용하여 'Blinking Task' 환경을 코드로 구현하였다. Gym 라이브러리는 모델과 환경이 데이터를 주고받을 수 있는 틀로, 구현된 모델은 해당 틀 안에서 행동을 하고 보상을 받으며 학습된다. 또한 clipping을 통해 정책이 급격히 바뀌는 것을 방지할 수 있는는 PPO 알고리즘을 기반으로 강화학습(RL) 에이전트 모델을 설계하였다.

A. 환경 설계

플래시는 $t = kT_{true}$ (k는 정수) 시점 마다 발생하며, 환경은 마지막 플래시 시각 t_{last}와 다음 플래시 시각 t_{next}을 추적한다. Gym 라이브러리의 spaces를 이용하여 관측 공간을 float32형의 3차원 벡터 [flash_on, time_since_last_flash, vigilant]으로 설정해주었고, 행동 공간은 2개의 이산 행동 (0=클릭 없음, 1=클릭)으로 설정해주었다.

a. 관측

매 시점 관측 벡터는 다음과 같이 구성된다

$$o_t = [flash\ on,\ t - t_{true},\ v_t]$$

flash_on은 현재 플래시가 켜져있는지 나타내는 이진값이며, 두 번째 항은 예측값과 플래시 시간의 차, 세 번째 항은 경계 상태(vigilance) 여부를 나타낸다.

b. 내부시계(Internal clock)

정책 네트워크는 플래시 주기의 예측값 $\widehat{T}$를 리턴하며, 이를 이용해 internal clock의
잔여 시간을 계산하였다.

$$r_t = max(0,\ \widehat{T} - (t - t_{last}))$$

내부 시계는 일정 시간 이후 경계 상태를 유발하여 클릭 가능성과 모델의 반응 민첩성을 높이는데 활용된다.

c. 운동 지연(Motor delay)

클릭은 일정 운동 지연 τ_m이후 발생한다. 다음 중 하나가 랜덤하게 샘플링되며,
클릭 시각은 $t_{click} = t + \tau_m$으로 계산되어 기록된다.

$$(\text{절단 정규분포})\ \tau_m = max(0, N(\mu_m, \sigma_m^2))$$

$$(\text{로그 정규분포})\ \tau_m \sim LogNormal(\mu_{log}, \sigma_{log}^2)$$

d. 경계 상태**(Vigilance)**

내부 시계가 종료되거나 종료되기 직전에는 일시적으로 $v_t > 0$이 되며, 이는 플래시에 대한 반응 준비도가 증가하여 운동지연이 축소된 상태를 의미한다.

e. 불안 상태**(Anticipation)**

보수적으로 학습되는 것을 막기 위해, 내부 시계가 거의 끝나가는 시점에 $(0.1 < r_t < 0.4)$ 에는 확률적으로 클릭을 강제하는 탐색 요소를 추가하였다. 이를 통해 초기 학습 단계에서 조기 클릭의 발생을 보장한다.

B. 보상 함수 설계

보상은 시간적으로 정확한 반응을 유도하면서도 인간처럼 일찍 혹은 늦게 반응할 수 있는 유연성을 허용하도록 설계되었다. 클릭 시각과 플래시 시각의 차이를 $\delta = t_{click} - t_f$라고 하면, 매칭된 클릭에 대한 보상은 다음과 같다.

$$R(\delta) = exp(-\frac{|\delta|}{\tau}) - \lambda$$

여기에서 τ는 시간 오차에 대한 허용도이고, λ는 불필요한 클릭을 억제하기 위한 미세한 페널티이다. 매칭 되지 않은 클릭은 -0.2의 보상을 부여한다. 이 함수는 플래시와 가까울 수록 높은 보상을, 시차가 커질 수록 지수적으로 낮은 보상을 주며 좌우 대칭적 형태로 설계되어있다. 음의 δ에 더 완화된 페널티를 주어 조기 클릭을 유도할 수 있다.

C. 학습과 기록

시간의 의존성과 내부 시계의 누적 상태를 모델링하기 위해 순환 신경망(LSTM) 기반의 정책을 사용하였다. 또한 정책은 PPO(Proximal Policy Optimization) 알고리즘을 사용하여 학습된다.

각 에피소드마다 플래시 발생 시각(t_f), 클릭 시각(t_{click}), 플래시-클릭 매칭쌍, 시간 차이를 계산하였다. 학습 이후 시간차의 평균, 중앙값, 표준편차, 반응시간 분포의 비대칭도, 조기반응 비율과 지연반응 비율, 비매칭 클릭률을 기준으로 에이전트의 행동을 분석하였다.

3. Flappy bird

Task 1과 마찬가지로 시각적 단서에 기반한 타이밍 과제(Visually Cued Temporal Pointing)인 'Flappy Bird Task'에 대한 데이터 수집 환경을 구성하고 실험을 수행하였다. 실험에는 조원 4명이 참여했으며, 개인당 약 150회의 시도를 기록하였다. 본 실험에서는 파이프 통과를 위한 점프 구간을 진입 구간인 Region A와 통과 구간인 Region B로 나누어 정의하고, 각 구간에서의 인간 반응 분포와

성공률을 분석하였다. Python과 Gym 라이브러리를 이용하여 강화학습 에이전트가 상호작용할 수 있는 'Flappy Bird' 환경을 구현하였다. 이 환경은 결정론적인 물리 법칙을 따르지만, 랜덤한 파이프 높이 생성을 통해 매번 다른 상황을 연출한다. 본 연구에서는 시계열 데이터 처리에 강점이 있는 LSTM(Long Short-Term Memory) 기반의 정책 네트워크를 사용하였으며, PPO(Proximal Policy Optimization) 알고리즘을 통해 에이전트를 학습시켰다.

A. 환경 설계

Task의 난이도는 물리학적 변수에 의해 결정된다. GRAVITY(y축 중력가속도), FLAP_VY(점프 시 초기 속도), PIPE_SPEED(파이프 이동 속도), PIPE_GAP(파이프 간격)을 조절하여 난이도를 변경하였으며, 파이프의 간격이 좁거나 이동 속도가 빠를수록 과제의 수행 난이도(Index of Difficulty)가 상승하는 구조를 가진다. 게임은 매 시도(Trial)마다 랜덤한 높이의 파이프가 생성되며 시작된다. 에이전트(새)는 중력의 영향을 받으며 수직 운동을 하고, 파이프는 일정한 속도로 수평 이동한다. 행동 공간은 이산적(0=행동 없음, 1=점프)으로 설정되었으나, 인간의 행동 패턴을 정밀하게 모사하기 위해 사용자가 스페이스 바를 두 번 눌러 파이프를 통과하는 시나리오를 채택하였다.

a. 관측 **(Observation)**

매 시점(time step) 에이전트가 환경으로부터 받아들이는 관측 벡터 ot는 다음과 같은 물리적 상태 정보들로 구성된다.

$$o_t = [y, v_y, y_{gap}, x_{dist}]$$

- y, v_y : 새의 현재 y축 좌표 및 y축 방향 속도
- y_{gap} : 전방에 위치한 파이프 사이의 중심(gap) 높이 좌표
- x_{dist} : 현재 위치에서 파이프까지 남은 수평 거리

이러한 관측 정보는 에이전트가 현재 자신의 위치와 목표 지점(Region A, B)을 인식하고 최적의 경로를 계획하는 데 사용된다.

b. 운동 지연 **(Motor Delay)**

클릭은 일정 운동 지연 τ_m 이후 발생한다. 다음 중 하나가 랜덤하게 샘플링되며,
클릭 시각은 $t_{click} = t + \tau_m$ 으로 계산되어 기록된다.

$$\text{(절단 정규분포)}\ \tau_m = max(0, N(\mu_m, \sigma_m^2))$$

$$\text{(로그 정규분포)}\ \tau_m \sim LogNormal(\mu_{log}, \sigma_{log}^2)$$

c. 노이즈 **(Noise)**

완벽한 기계적 반응을 방지하고 인간의 감각적 오차를 재현하기 위해, 관측된 상태 정보나 행동 결정 과정에 가우시안 노이즈(Gaussian Noise)를 주입하였다. 이를 통해 에이전트는 불확실성 하에서 의사결정을 내리는 법을 학습한다.

B. 보상 함수 설계

보상 함수는 파이프 통과라는 목표 달성과 더불어, 인간 데이터에서 관측된 '이상적인 타이밍'을 학습하도록 설계되었다.

- 타이밍 보상: Region A와 Region B 내에서 성공적인 궤적을 만들어내는 적절한 타이밍에 점프를 수행할 경우 보상이 증가한다.
- 성공 보상: 파이프를 충돌 없이 통과할 경우 큰 보상을 부여한다.
- 실패 패널티: 파이프에 충돌하거나 화면 경계(천장/바닥)를 이탈하여 게임이 종료될 경우 페널티를 부여한다.

C. 학습과 기록

에이전트는 PPO 알고리즘을 통해 보상을 최대화하는 방향으로 정책을 업데이트하며, 안정적인 학습을 위해 클리핑(Clipping) 기법을 적용하였다. 데이터 분석을 위해 매 시도마다 점프가 가능한 구역에 도달한 시점을 0ms로 기준 잡고(Reference Time), 실제 에이전트(혹은 인간)가 점프 입력을 수행한 시간과의 차이를 기록하였다. 이 로그 데이터를 바탕으로 Region A(진입)와 Region B(통과)에서의 반응 시간 분포, 평균 오차, 표준편차 등을 산출하여 인간 데이터와 모델 데이터의 유사성을 검증하였다.

6. 연구 결과

1. Blinking Task

A. 사람의 반응 분포

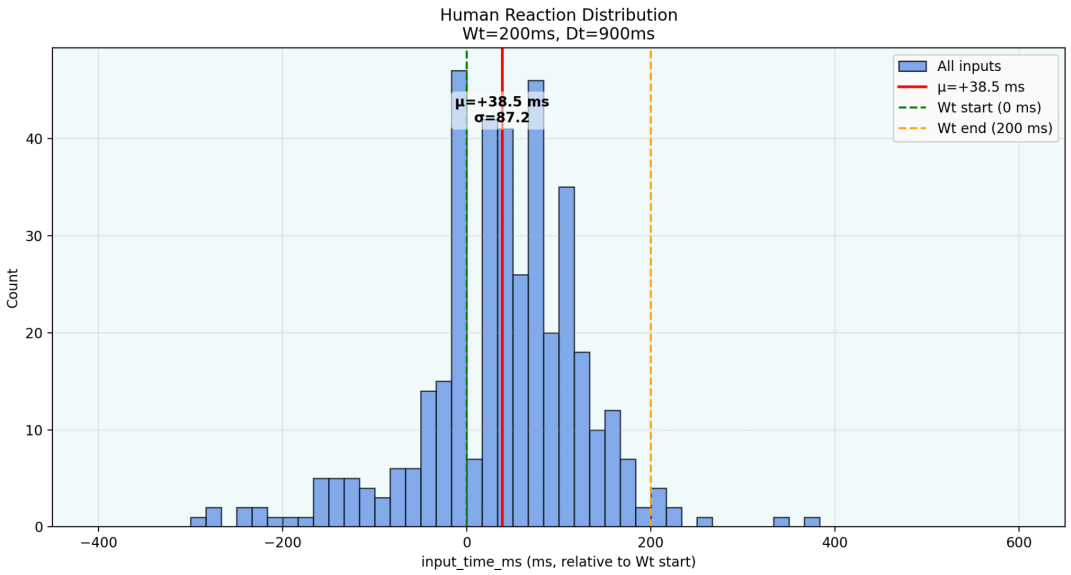

[그림 3] Wt=200ms, Dt=900ms 일 때 사람 반응 분포

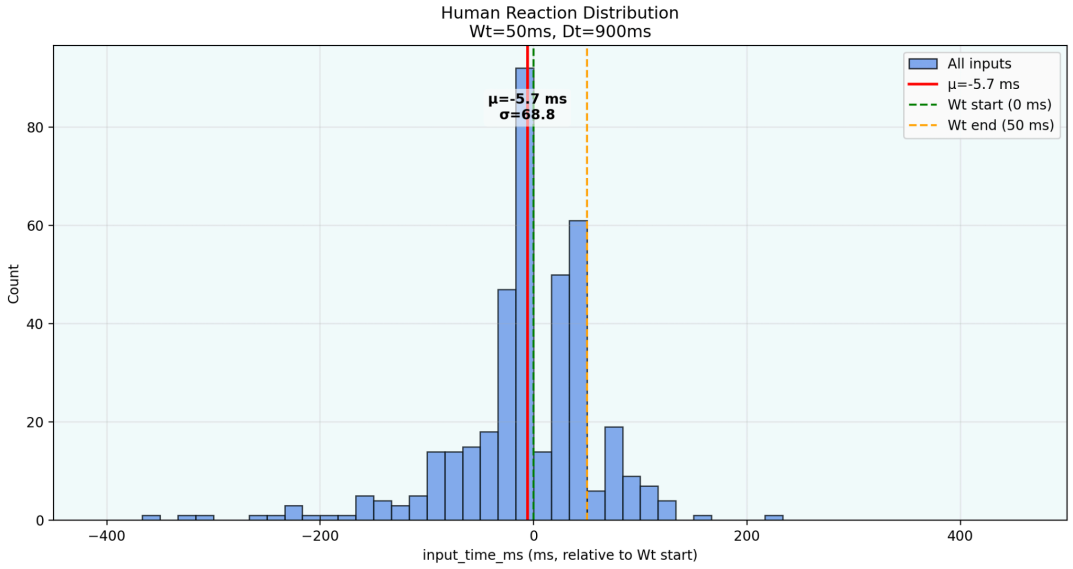

[그림 4] Wt=50ms, Dt=900ms 일 때 사람 반응 분포

위 그래프는 사람의 상대적 클릭 시간 분포로, 0s 가 클릭해야했던 타이밍에 해당하며 특정 시간대에 사람이 얼마나 빈번하게 클릭했는지 시각적으로 확인할 수 있다. 사람 데이터를 분석한 결과, 참가자들은 대체로 플래시 발생 시점보다 늦은 50ms에 클릭하는 경향을 보인다. 이는 내부시계(internal clock)가 만료되더라도, 플래시와 같은 비쥬얼 큐가 없으면 클릭을 잘 수행하지 않기 때문으로 해석할 수 있다.

또한, 클릭 타이밍의 평균이 -5.7ms, 38.5ms로 플래시 발생 시점(0ms)에 근접함에도 불구하고, 실제로 정확한 플래시 시점에 클릭하는 경우는 매우 드물게 나타난다. 이는 anticipatory click 현상과 internal clock의 오차로 인해 일부 클릭이 플래시 이전에 발생할 수 있으나, 플래시를 실제로 관측한 이후 클릭은 반응 지연으로 인해 필연적으로 플래시 시점 이후에 발생하기 때문이다.

결과적으로 사람의 클릭 타이밍 분포는 플래시 시점을 중심으로 약간 지연되며, 정확한 시점에 클릭되는 경우는 극히 제한적임을 확인할 수 있다.

ID_t	W_t	D_t	μ	σ
1.56	200	600	35.5ms	92.6
2.17	200	900	38.5ms	87.2
2.36	200	1200	43.9 ms	104.3
2.59	116.7	600	21.0ms	79.0
2.95	116.7	900	21.0 ms	72.3

3.37	116.7	1200	17.2 ms	81.3
3.59	50	600	-11.1 ms	66.6
4.17	50	900	-5.7 ms	68.8
4.59	50	1200	-17.3 ms	82.4

[표 1] 조건에 따른 사람 반응 분포의 평균 및 분산

B. 난이도에 따른 실패율

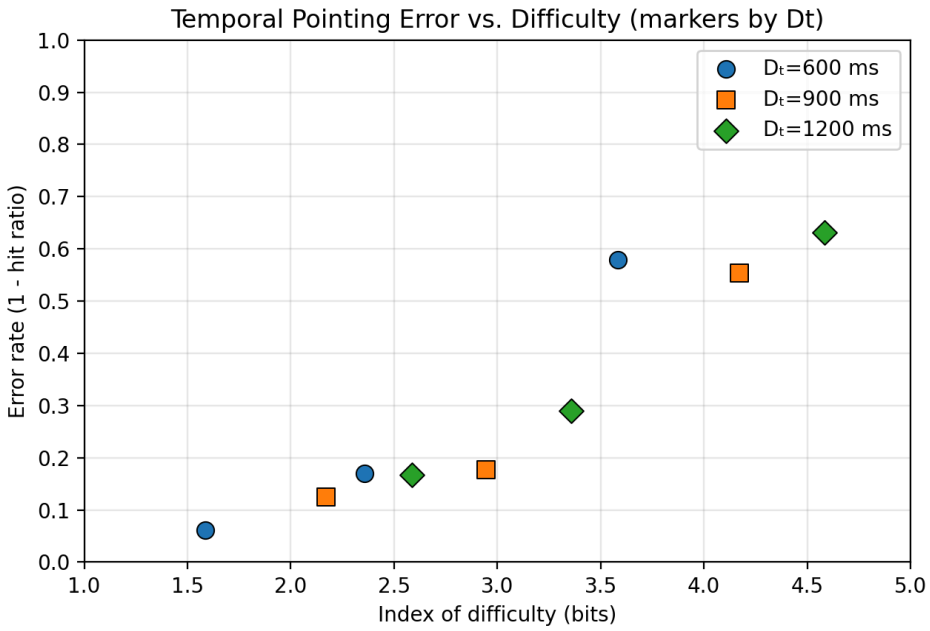

[그림 5] 난이도에 대한 실패율 그래프

위 그래프는 플래시의 간격에 따라 색을 나누어 표기되었다. 플래시의 간격이 길어지고 잔존 시간이 감소함에 따라 난이도가 증가하며, 이러한 난이도가 사람의 클릭 오차율에 어떤 영향을 미치는지 시각화하기 위한 자료이다. 그래프를 통해 사람의 클릭 오차율이 난이도에 비례하여 실패율이 높아지는 것을 확인할 수 있다. 이는 실험자가 클릭의 정확성에 대한 확신이 없을 수록 비쥬얼 큐가 아닌 내부시계에 의존하여 클릭을 수행하기 때문이다.

C. 모델 데이터

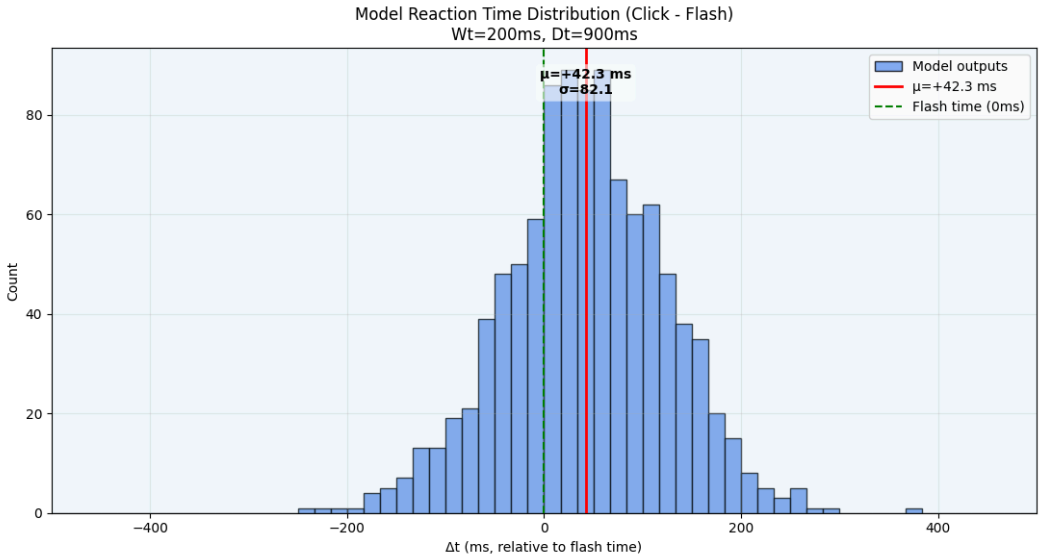

[그림 6] 모델의 반응 시간 분포

Lee & Oulasvirta(2016)의 ID□–오차율 모델과의 일치도를 분석한 결과, 본 모델의 평균 클릭 오차율은 인간 실험 데이터에 비해 약 0.04초 높게 나타났으며, 표준편차 역시 약 0.065초 큰 것으로 확인되었다. 그럼에도 불구하고 이러한 차이는 매우 미미한 수준으로, 모델 데이터가 인간 수행 데이터를 성공적으로 모사하고 있다고 판단할 수 있다. 이러한 오차는 데이터 분포의 특성에서 기인한 것으로 보인다. 모델 데이터는 난이도 조건별로 1000개 이상의 시도가 포함되어 정규분포 형태가 매우 안정적으로 나타난 반면, 인간 데이터는 조건별로 약 400개의 데이터만을 포함하고 있어 완전한 정규성을 확보하기 어렵다.

다만 인간 데이터는 특정 값 주변에 측정치가 집중되는 'spiked Gaussian' 형태를 보였으나, 모델 데이터는 이상치가 적고 이상적으로 매끄러운 종 모양의 Gaussian 개형을 갖는다. 이는 에이전트의 클릭 결정이 확률적 규칙에 기반하기 때문으로 해석된다. 따라서 인간이 특정 지점에서 클릭하는 경향이 발생하는 근본적 요인을 규명한다면, 향후 모델의 인간 수행 모사 정확도를 한층 더 향상시킬 수 있을 것으로 판단된다.

2. Flappy bird

A. 사람 반응 분포

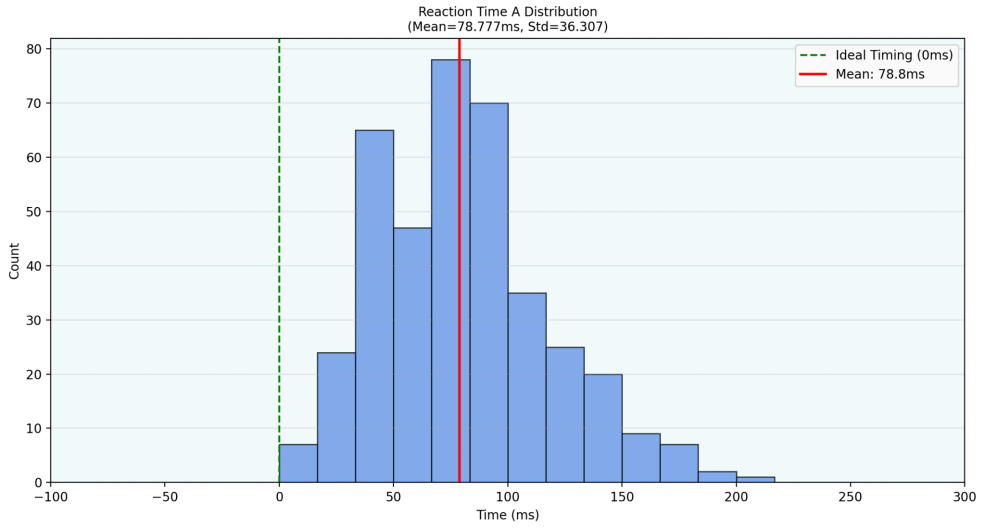

[그림 7] Region A 사람 반응 시간 분포

[그림 8] Region B 사람 반응 시간 분포

사람 데이터를 분석한 결과, Region A에서 참가자들은 조기클릭 없이 점프 가능 시점에서부터 70ms정도 지난 시점에 클릭하는 것으로 나타났다. Flappy bird task의 경우 점프 가능 시점이 언제인지 명확하게 주어지지 않으므로, 파이프에 부딪히지 않도록 비교적 더 늦게 클릭하는 경향이 있는 것으로 보인다.

Region B의 경우, 조기클릭이 발생하였고, 점프 가능 시점부터 평균 100ms 정도 지난 시점에 클릭하는 것으로 나타났다. 또한, Region A에 비해 분산이 더 크게 나왔다. Region B는 Wt가 더 크고 균일하기 때문인 것으로 보인다.

B. 모델 데이터

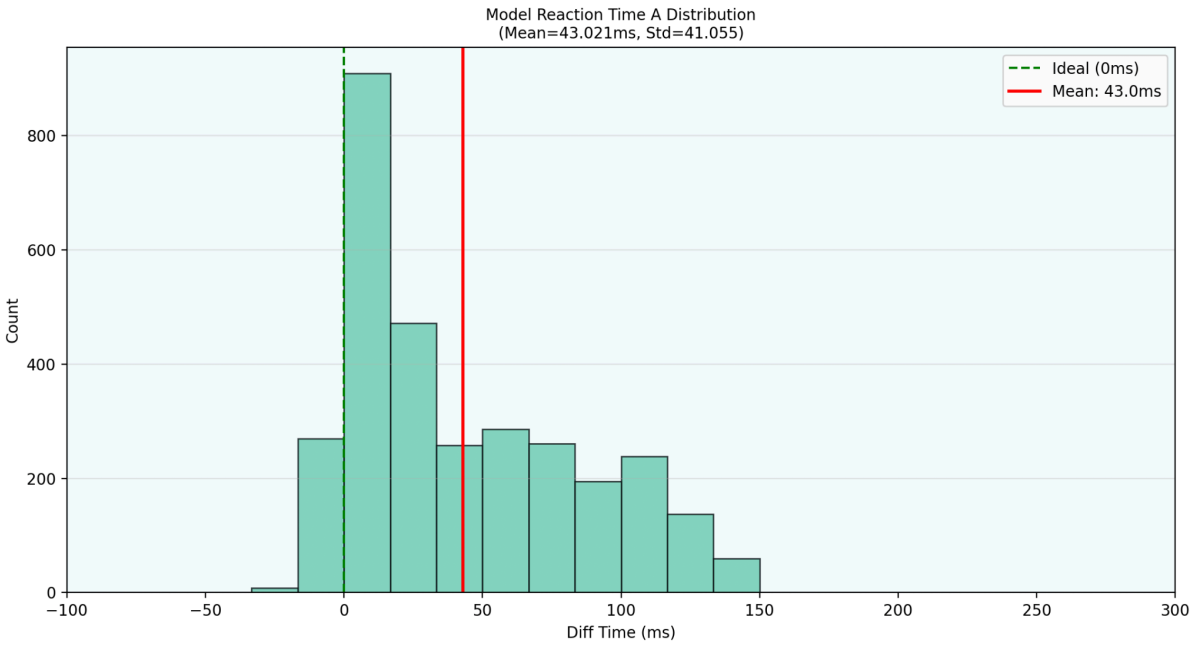

[그림 9] Region A 모델 반응 시간 분포

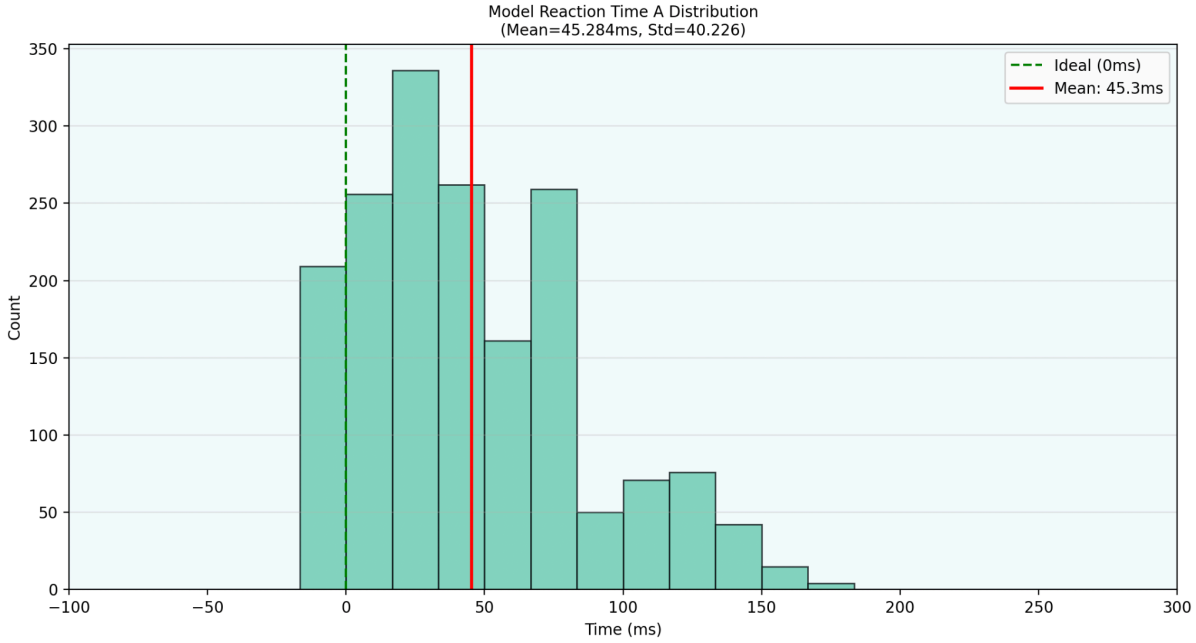

[그림 10] Region B 모델 반응 시간 분포

Region A에서 사람보다 모델이 평균 30ms 정도 더 빨리 클릭하는 경향을 보였다. 사람은 조기 클릭을 하거나 0초 부근에서 클릭을 거의 하지 않았지만, 모델은 대부분의 클릭이 0초 부근에서 일어났다. Region B의 경우에도 조기클릭이 발생하거나 0초 부근에서 클릭이 발생하였다.

따라서 Region A, Region B 모두, 어느정도 경향성은 모사를 했지만 사람의 반응 분포를 완벽하게 모사하지는 못했다. 이는 현재 구현한 noise, delay 등의 constraint와 reward 설계가 분포 자체를 모사하도록 유도하지 못하였기 때문인 것으로 보인다. 특히, 사람의 경우 언제부터 점프가 가능한지 알지 못하므로 늦게 점프하는 경향이 있었는데, RL 모델의 경우 점프가 가능한 실제 시점을 기준으로 reward를 설계하였기때문에 차이가 발생한 것으로 보인다. 이 점을 보완하도록 reward를 설계한다면, 사람과 더 유사한 분포를 형성하는 모델을 만들 수 있을 것으로 기대된다.

7. 결론 및 기대 효과

본 연구는 기존 Computational Rationality 프레임워크가 주로 공간적 정보 중심의 과제를 다루었다는 한계를 확장하여, 시간적 정보를 인지/기억/예측하는 인간의 행동원리를 모사하는데 목적을 두었다. 이를 검증하기 위해 두 가지 실험을 수행하였으며, 그 결과는 다음과 같다. 첫째, 실험 1(Blinking Task)에서 인간은 시각적 단서(Visual Cue) 부재 시 내부 시계(Internal Clock)에 의존함에 따라 플래시 발생 시점보다 약 50ms 지연된 시점에 반응하는 경향을 보였다. 둘째, 실험2(Flappy Bird Task)에서는 동적인 환경에서 인간의 반응이 주로 80~100ms 구간에 집중되고, 특히

진입 구간(Region A)에서의 조기 반응(Early input)이 줄어드는 특징이 나타났다. 설계한 강화학습 모델 역시 이러한 과제별 특성과 구간별 반응 분포 차이를 재현해냈다.

우리 연구팀은 인간 데이터가 특정 값에 집중되는 'Spiked Gaussian' 형태를 보이는 반면, 모델은 확률적 규칙에 기반하기에 이상적인 정규분포(Gaussian)를 그린다는 분포 형태 차이를 확인했다. 그러나 이를 제외한 반응 지연, 난이도에 따른 실패율 증가 등 주요 행동 패턴이 통계적으로 매우 유사하게 나타났다. 이는 본 시뮬레이션 환경과 에이전트가 단순한 기계적 패턴을 학습을 넘어, '인간은 주어진 인지·제약 하에서 보상을 최대화하는 최적의 판단을 한다'는 Computational Rationality(CR)의 핵심 전제에 부합하며 인간의 불완전한 내부 시계 및 인지적 제약을 성공적으로 반영했다고 평가한다.

본 연구의 모델을 활용함으로써 얻을 수 있는 기대효과는 다음과 같다. 첫째, 인간의 행동 기저 원리를 파악하는 분석 도구로 활용될 수 있다. 에이전트가 학습한 정책(Policy)을 역으로 분석함으로써, 겉으로 드러난 행동 기저에 있는 인간의 의도와 전략이 무엇인지, 그리고 인지적 제약이 의사결정에 구체적으로 어떤 영향을 미치는지 규명하는데 기여할 수 있다. 이는 인간의 행동 데이터만으로는 알기 어려운 '인간 인지 구조'를 이해하는 새로운 접근법이 될 것이다. 둘째, 연구 비용과 시간의 획기적인 절감이다. 모델을 통해 다양한 조건에서 대규모 가상 표본을 생성함으로써, 실제 인간 실험에 소요되는 시간/비용과 같은 리소스를 줄이고 환경이나 난이도 변화가 반응에 미치는 영향을 효율적으로 탐색할 수 있다. 셋째, 다양한 응용 분야에서의 활용 가능성이다. 인간 반응 특성을 고려한 과제 설계, 게임 난이도 조정, UI/UX 개선 등 실무적인 분야 뿐 아니라, 인지심리학 및 신경과학 연구에서 인간 행동 데이터를 보완하는 자료로도 활용될 수 있을 것이다.

8. 한계

본 연구에서 사용한 temporal pointing 강화학습 모델은 인간의 시간 지각과 입력 오류 패턴을 모사하기 위한 유용한 도구이지만, 여러 한계점도 존재한다. 첫째, 모델이 시간 간격을 배우는 과정은 인간의 생물학적 메커니즘과 구조적으로 다르다. 인간의 타이밍 행동은 뇌 내에서 다양한 요인의 영향을 받지만, 본 모델은 PPO와 LSTM을 이용해 보상 신호를 최적화하는 방식으로 학습한다. 따라서 모델이 생성하는 오류 분포나 반응 패턴이 인간과 비슷하게 보일 수는 있지만, 그 안에서 실제로 작동하는 과정은 인간의 지각 체계와는 간극이 있다.

둘째, 모델이 입력으로 받는 정보는 flash 신호, 경과 시간, vigilant 값처럼 매우 정제된 수치 정보이기 때문에, 실제 사람이 경험하는 복잡하고 잡음이 많은 감각 환경을 충분히 반영하지 못한다. 이런 단순화된 입력 구조는 모델이 인간보다 빠르고 안정적으로 시간 간격을 내재화하게 만들며, 결국 인간에게서 흔히 나타나는 주의 변화나 감각적 불확실성의 특성이 재현되지 않을 수 있다. 또한 운동 반응 지연(motor delay)과 vigilant, anticipatory click 같은 요소도 단순한 규칙과 분포로 구현되어 있어, 실제 인간의 반응시간 분포나 주의 전략에 비해 지나치게 단순화되어 있다.

마지막으로, 성공·실패 판정이 특정 시간창(match window)에 의해 기계적으로 결정되기 때문에, 사람이 주관적으로 잘 클릭했다고 느끼는 기준과 차이가 있을 수 있다. 그럼에도 불구하고, 이 모델은 난이도 변화에 따른 오류율 증가나 반응 시간 분포의

전형적 형태 등 인간 행동의 전반적 경향을 재현하는 데에는 의미 있는 도구이며, 실험 조건의 변화가 시간 지각과 행동 오류에 어떤 영향을 주는지 비교·분석하는 계산 실험용 모델로 충분한 가치가 있다.

9. 팀원 구성 및 역할

- 팀장 : 박성용
- 팀원 : 김진주, 김환욱, 이용주

모든 팀원은 설계의 다양성과 상호보완을 위해 다음을 공동 수행하였다.

1. 데이터 수집 환경 구성 및 분석
   - 실제 데이터 수집과 분석을 위한 환경 구성 후 데이터 수집 및 분석
2. 강화학습 모델 설계 및 구현
   - 에이전트 학습을 위한 알고리즘, 모델 선정 후 학습 환경 구현
3. 알고리즘 개선
   - 수집한 인간 데이터와 비교 분석 후, 인간의 행동 분포와 행동 패턴을 더 잘 묘사하는 알고리즘으로 개선

10. 참고 문헌

1) Ebbinghaus, H. (1885). *Über das Gedächtnis: Untersuchungen zur experimentellen Psychologie*. Leipzig: Duncker Humblot.
2) Ratcliff, R. (1979). *Group reaction time distributions and an analysis of distribution statistics*. *Psychological Bulletin, 86*(3)
3) Reason, J. (1990). *Human error*. Cambridge: Cambridge University Press.
4) Gibbon, J. (1977). *Scalar expectancy theory and Weber's law in animal timing*. *Psychological Review,*
5) Byungjoo Lee and Antti Oulasvirta. "Modelling Error Rates in Temporal Pointing." Proceedings of the 2016 CHI Conference on Human Factors in Computing Systems. 2016.
6) Deverett, Ben, et al. "Interval timing in deep reinforcement learning agents." *Advances in Neural Information Processing Systems* 32 (2019).
7) Oulasvirta, Antti, Jussi PP Jokinen, and Andrew Howes. "Computational rationality as a theory of interaction." *Proceedings of the 2022 CHI Conference on Human Factors in Computing Systems*. 2022.
8) Moon, Hee-Seung, et al. "Real-time 3d target inference via biomechanical simulation." *Proceedings of the 2024 CHI Conference on Human Factors in Computing Systems*. 2024.